

Processo ETL e Modelo Dimensional do DW — Comentários

Avaliação 02 — Parte II · Comentários sobre o desenvolvimento do processo ETL e do modelo dimensional: escolhas feitas, problemas e observações encontrados, e conclusão à luz dos objetivos que motivaram a solução de Data Warehouse.

1. Objetivo e visão geral da solução

Seis locadoras independentes passaram a compartilhar pátios e decidiram constituir um **Data Warehouse integrado** para gerar Relatórios Gerenciais globais e sustentar a análise de *previsão de ocupação de pátio* por Cadeia de Markov. Como cada empresa mantém o seu próprio SGBD relacional (OLTP), o desafio central da Parte II não é guardar dados, e sim **integrar fontes heterogêneas** em um modelo único no qual “veículo”, “pátio”, “tempo” e “empresa” signifiquem a mesma coisa em qualquer relatório. A solução adotada é um pipeline ETL clássico em três tempos — *Extração* → *Transformação* → *Carga* — alimentando um **esquema estrela** com três tabelas de fato e dimensões conformadas.

Foram integradas **quatro fontes OLTP** da turma: a do próprio grupo (`idevlimes/locadora-oltp`) e mais três escolhidas entre os esquemas publicados (`gupessanha`, `tadeupires`, `valviessejoao`). As cópias dos esquemas dessas fontes acompanham a entrega em `docs/esquemas-outros-grupos/` e foram a base concreta para as decisões de mapeamento descritas adiante.

2. Arquitetura do pipeline ETL

O pipeline foi dividido em quatro scripts SQL executados em ordem, isolando responsabilidades e permitindo reprocessamento parcial:

#	Script	Etapa	Papel
01	<code>01_ddl_dw_estrela.sql</code>	DDL	Cria o esquema estrela do DW (dimensões + fatos + índices).
02	<code>02_extracao_staging.sql</code>	Extração (E)	Cria a <i>staging area</i> e extrai as 4 fontes 1:1, preservando chave natural e linhagem.
03	<code>03_transformacao.sql</code>	Transformação (T)	Limpa e conforma domínios, pátios, UF e faixa etária na staging.
04	<code>04_carga_dw.sql</code>	Carga (L)	Gera surrogate keys e carrega dimensões e fatos a partir da staging conformada.
05	<code>05_relatorios_matriz.sql</code>	Consumo	Relatórios Gerenciais (a–d) e matriz estocástica de Markov.

Staging neutra, orientada a conceito

A área de staging foi modelada **por conceito do negócio** (cliente, veículo, pátio, reserva, locação, movimentação, empresa) e **não por fonte**. Cada tabela de *landing* recebe linhas de todas as fontes,

sempre carimbadas com `sistema_origem`. Essa decisão concentra a heterogeneidade em um único ponto — o bloco de extração de cada fonte é o único lugar que conhece os nomes reais de tabelas/colunas daquela fonte — e deixa o restante do pipeline trabalhar sobre um formato uniforme.

Acesso às fontes

Como todas as fontes são PostgreSQL independentes, a extração usa `postgres_fdw`: um *foreign server* por fonte, com o esquema remoto importado sob `src_<fonte>`. Credenciais ficam fora do versionamento (apenas o padrão de uso é documentado no script).

Tempos de acionamento das extrações

Conforme exigido, o agendamento foi especificado explicitamente:

- **Carga incremental diária às 01:00** — janela de menor tráfego das lojas físicas e do app, quando os OLTPs estão mais ociosos.
- **Reprocessamento/carga histórica completa** — semanal, domingo às 02:30.
- **Sequência do pipeline**: 01:00 extração → 02:00 transformação → 02:30 carga do DW → 03:00 refresh de relatórios.

O script de extração inclui o exemplo de agendamento correspondente com `pg_cron`.

3. Principais escolhas de modelagem

- **Três tabelas de fato (constelação)**. Reserva, locação e movimentação têm grãos e dimensionalidades distintas — intenção, aluguel realizado e fluxo físico da frota. Mantê-las separadas evita fatos esparsos e dá a granularidade correta a cada processo.
- **Dimensões conformadas**. As cinco dimensões são compartilhadas pelos três fatos, condição necessária para relatórios *globais* coerentes entre as seis locadoras.
- **Dim_Patio em papel múltiplo (role-playing)**. Uma única tabela física representa os papéis de retirada/devolução (locação) e origem/destino (movimentação), com *views* nomeando cada papel — sem duplicar a dimensão.
- **Surrogate keys**. Toda dimensão usa SK inteira, isolando o DW das chaves naturais heterogêneas das fontes. A chave natural e o `sistema_origem` são preservados para rastreabilidade/linhagem.
- **Membro “Não informado” (SK = -1)**. Cada dimensão tem um membro especial que recebe os fatos cujo atributo não pôde ser resolvido, garantindo integridade referencial sem descartar registros.
- **Dim_Tempo determinística**. Gerada por `generate_series` cobrindo o intervalo real dos fatos mais uma folga de 90 dias para reservas futuras (recorte “semana/mês que vem” do Relatório C).

4. Transformação e conformação — tratamentos aplicados

Problema na origem	Tratamento na staging (03)
Câmbio/transmissão com domínios textuais distintos ('A', 'Aut.', 'AUTOMATICO', 'Manual'...)	Normalizado para domínio fechado {Automático, Manual, Não informado}.

Problema na origem	Tratamento na staging (03)
UF escrita de formas diferentes ('RJ', 'Rio de Janeiro'...)	Conformada para sigla de 2 letras .
Idade ora como data de nascimento, ora como número	Faixa etária derivada (Jovem/Adulto/Sênior), usando idade direta ou calculada do nascimento.
Os 6 pátios compartilhados aparecem com ids próprios em cada fonte	Conformação por nome canônico (Galeão, Santos Dumont, Rodoviária, Rio Sul, Nova América, Barra) via palavras-chave no nome/endereço — Dim_Patio fica com ~6 linhas.
Mesmo id pode existir em duas fontes	Chave natural composta <code>sistema_origem#id_origem</code> evita colisão.
Campos ausentes (texto vazio, nulos)	COALESCE para defaults explícitos ('Não informado').

5. Problemas e observações encontrados

Heterogeneidade dos esquemas. Os quatro grupos modelaram o mesmo domínio com nomes de tabela/coluna diferentes (ex.: `cambio × transmissao`; `uf × estado`; `qtd_vagas × numero_vagas`; categoria em tabela `grupo` à parte `×` coluna direta). Por isso a leitura das cópias dos esquemas dos outros grupos foi indispensável: cada bloco de extração teve de ser escrito contra o esquema *real* da fonte, não contra um suposto padrão comum.

- **Lacunas da fonte própria.** O OLTP do grupo (Parte I) não guarda cidade/estado do cliente, nem marca/categoria/mecanização/empresa do veículo, nem uma tabela de empresa. Esses campos do DW são supridos por outras fontes ou recebem default conformado, e a empresa é derivada da identidade da fonte — uma observação importante sobre os limites do dado de origem.
- **“Grupo” do veículo como conceito, não como tabela.** O eixo central dos relatórios A–D é o “grupo/categoria” do veículo, mas ele vive em lugares diferentes conforme a fonte (tabela `grupo`, coluna `categoria`, ou inferido da reserva). A conformação para um único atributo `categoria` foi um dos pontos mais sensíveis.
- **Origem da frota (própria × associada).** O Relatório A exige distinguir veículos da empresa dona do pátio dos veículos das associadas; isso só é possível porque a movimentação carrega a empresa do veículo e a `Dim_Patio` carrega a empresa dona — comparadas na consulta.
- **Posição atual do veículo.** Não há um “estado atual” nas fontes; a posição corrente foi derivada como o *destino da última movimentação* registrada (janela por `sk_tempo`), insumo direto do Controle de Pátio.
- **Matriz de Markov.** A matriz estocástica é calculada por $P(i \rightarrow j) = \text{mov}(i, j) / \sum_j \text{mov}(i, j)$; a diagonal é o percentual que retorna ao pátio de origem. O script inclui uma conferência de que cada linha soma 1,0000.

6. Conclusão

O Data Warehouse construído atende aos objetivos que motivaram a sua adoção. Ao consolidar quatro sistemas transacionais independentes em um único esquema estrela com dimensões conformadas, ele

torna possível o que nenhum OLTP isolado conseguia: **Relatórios Gerenciais globais** que enxergam a associação como um todo — quantitativo de pátio por grupo e origem, controle de locações com previsão de devolução, reservas futuras por pátio e cidade de origem, e ranking dos grupos mais alugados — todos sobre uma base histórica integrada e com semântica única. A **análise preditiva de ocupação** por Cadeia de Markov, por sua vez, é alcançada diretamente a partir de `Fato_Movimentacao`, demonstrando que o modelo dimensional não só responde ao passado como sustenta decisões sobre o futuro (redistribuição de frota entre pátios).

O esforço concentrou-se, como esperado em um cenário multi-fonte, na etapa de **transformação/conformação**: foi ela que absorveu a heterogeneidade dos esquemas e as lacunas de dados, entregando dimensões limpas e comparáveis. A separação clara entre staging neutra, conformação e carga — com surrogate keys, linhagem e membros “Não informado” — resultou em um pipeline reexecutável e auditável, e confirma o Data Warehouse como a arquitetura adequada para integração analítica de sistemas operativos que continuarão independentes.